Laboratorio 2

Emmanuel Escobar Santos

14/04/2026

Laboratorio 2

- Emmanuel Escobar Santos

14/04/2026

1) ¿Cómo interpretar un componente con variables de diferentes subsistemas?

- Al aplicar PCA las componentes principales resultantes son una combinación lineal de las características originales de los datos, como hemos visto en clase las CP en sí no tienen interpretación directa, su interpretación se logra por medio de ver la calidad de representación de las variables originales sobre ese componente, cuales son las que más influyen y tambien la cantidad de varianza total que preserva.

En este caso como las variables pertenecen a distintos subsistemas de la infraestructura de datos distribuida si un componente combina variables de varios subsistemas, se puede interpretar como una variable general que representa el estado de varios subsistemas.

* No se necesita R para esto, es interpretación y conceptos.

2) Proponer indicador y ¿Como validar su calidad?

- Para validar el indicador se puede usar el porcentaje acumulado de variabilidad explicada que en este caso usando SCP es de más del 93% lo que garantiza fiabilidad en el indicador ya que se preserva la mayor parte de la variabilidad de los datos originales.

3) La metrica de calidad de representación vista en clase son los cosenos cuadrados (tambien las contribuciones a la componente pero esas no miden que tan bien esta representada la variable por la componente sino que variables aportaron más en esa componente.

Entre más cercano a 1 y entre más alineada con el eje mejor.

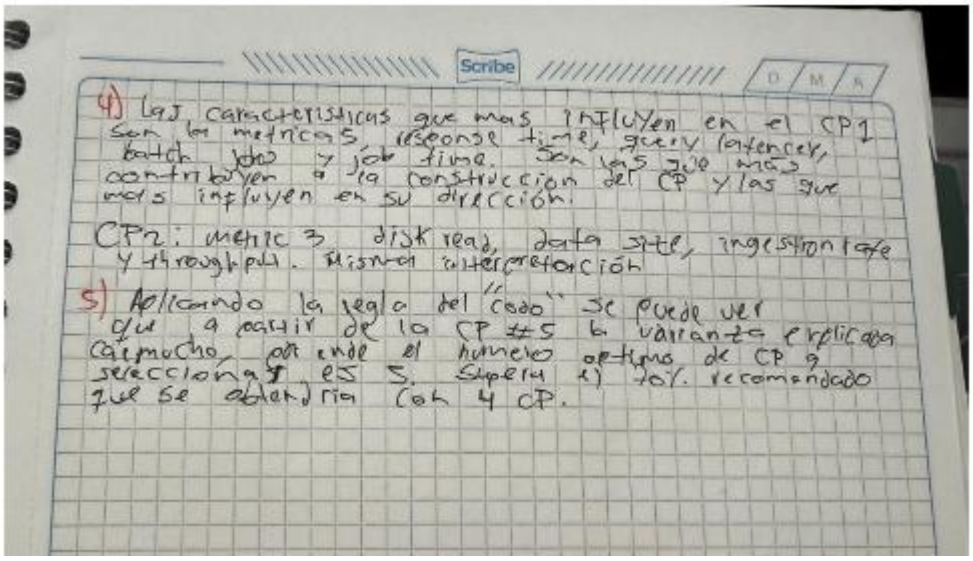

4) Las características que mas influyen en el CP1 son las metricas response time, query latency, batch jobs y job time. Son las que mas contribuyen a la construccion del CP y las que mas influyen en su dirección.

CP2: metric 3 disk read, data size, ingestion rate y throughput. Misma interpretación

5) Aplicando la regla del "codo" se puede ver que a partir de la CP #5 la varianza explicada casi mucho, por ende el numero optimo de CP a seleccionar es 5. Supera el 70% recomendado que se obtendria con 4 CP.

1) ¿Cómo interpretar un componente con variables de diferentes subsistemas?

-Al aplicar PCA las componentes principales resultantes son una combinación lineal de las características originales de los datos, como hemos visto en clase las CP en si no tienen interpretación directa, su interpretación se logra por medio de ver la calidad de representación de las variables originales sobre ese componente, cuales son las que más influyen y también la cantidad de varianza total que preserva.

En este caso como las variables pertenecen a distintos subsistemas de la infraestructura de datos distribuida si un componente combina variables de varios subsistemas, se puede interpretar como una caracteristica general que representa el estado de varios subsistemas.

*No se necesita R para esto es interpretación y conceptos

2) Proponga un indicador con los resultados obtenidos ¿Cómo validaría la calidad del indicador propuesto?

-Para validar el indicador se puede usar el porcentaje acumulado de variabilidad explicadad que en este caso usando 5 CP es de mas del 93% lo que garantiza fiabilidad en el indicador ya que se preserva la mayor parte de la variabilidad de los datos originales.

CODIGO INDICADOR:

```
#Aplicar PCA
pca = PCA(muestra, ncp = 5, scale.unit = TRUE, graph = FALSE) #20 cp porque lo mas probable es
#que no se necesiten las demas, luego se analizara el resultado y se adecuara
#con solo 4 CP logramos mas del 70% de varianza preservada y con 5 +93% -> usare 5 aunque con 4 bastar
pca

#sacar vectores y valores propios
val = pca$eig
vec = pca$ind$coord
val
vec

#grafico de varianza explicada
fviz_eig(pca, addlabels = TRUE, ylim = c(0, 60))

#construccion del indice
coordenadas_proyectadas = pca$ind$coord
coordenadas_proyectadas
```

```
w1 = val[1, 1]
w2 = val[2, 1]
w3 = val[3, 1]
w4 = val[4, 1]
w5 = val[5, 1]
w1
w2
w3

indice = w1 * coordenadas_proyectadas[,1] + w2 * coordenadas_proyectadas[,2] + w3 * coordenadas_proye
indice

#reescalar indice de 0 a 100
indice_rescalado <- (indice - min(indice)) / (max(indice) - min(indice)) * 100
indice_rescalado
hist(indice_rescalado)
```

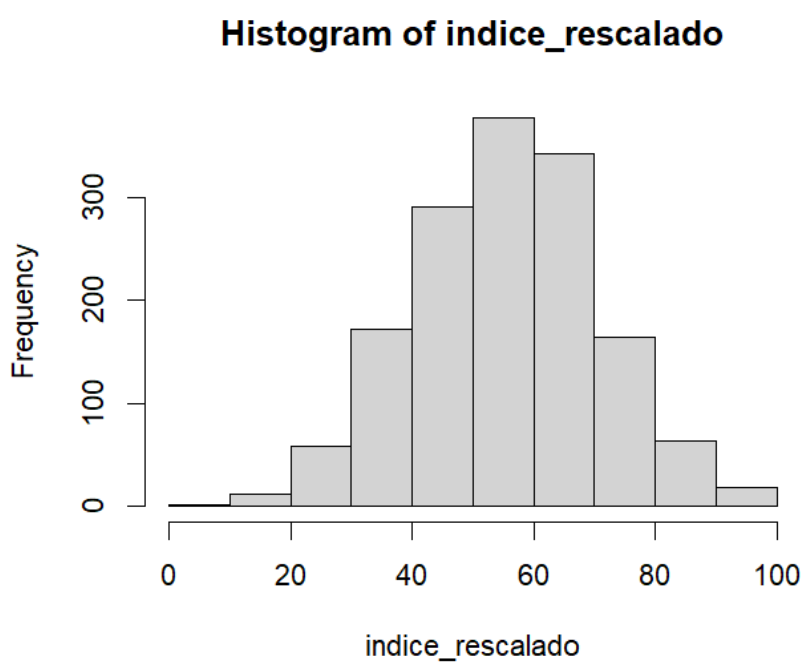

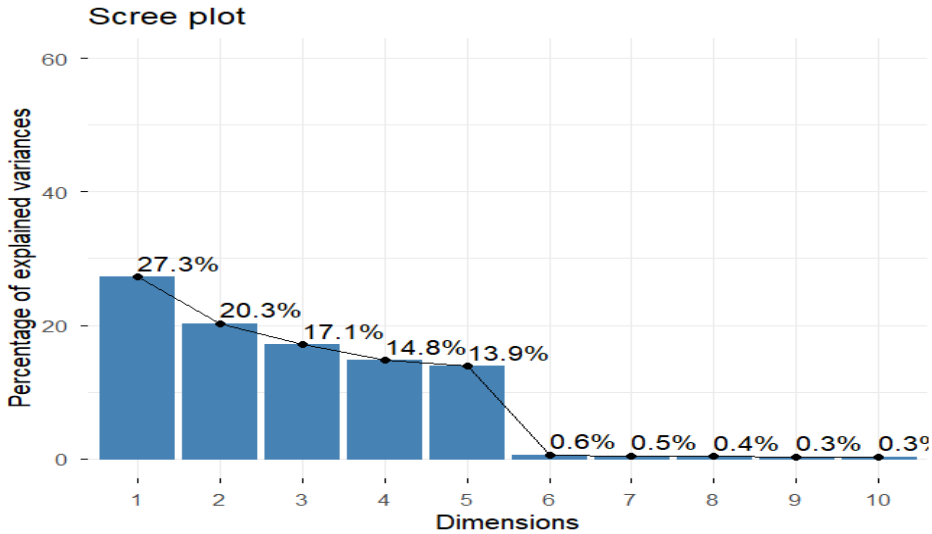

3) ¿Qué criterio usaría para decidir si una variable es bien representada?

-La métrica de calidad de representación vista en clase son los cosenos cuadrados (y también las contribuciones a la componente pero esas no miden que tan bien esta representada la variable por la componente sino que variables aportaron más en esa componente).

Entre mas cercano a 1 sea el valor del coseno cuadrado mejor representada está y entre mas alineada con el eje mejor.

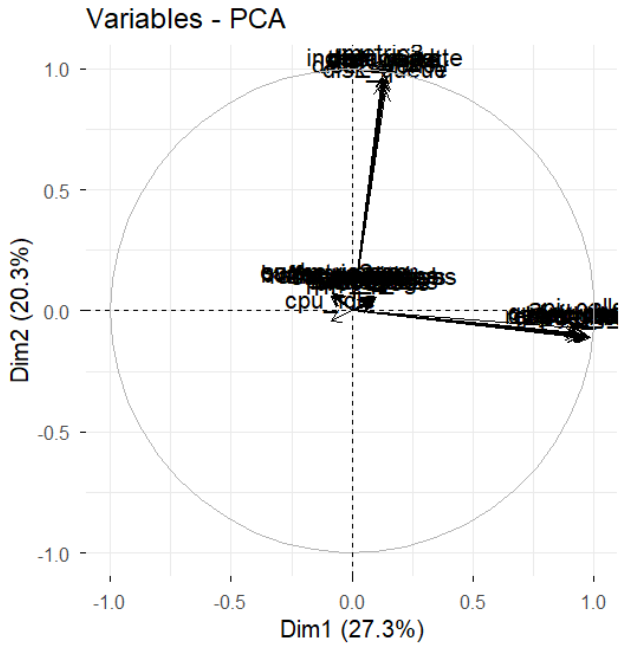

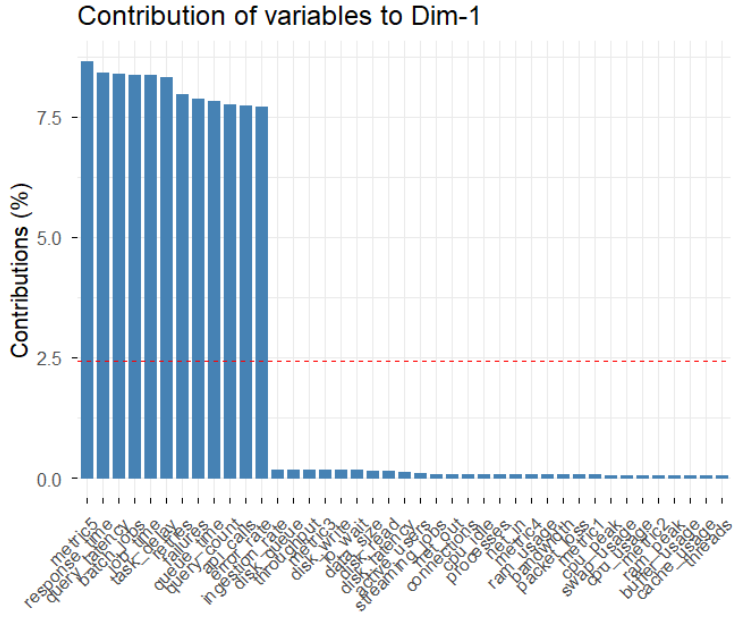

```r
#calidad de representacion
cosenos = pca$var$cos2
cosenos
fviz_pca_var(pca)
fviz_pca_var(pca, axes = c(3,4))
fviz_pca_ind(pca, axes = c(4,5))

#contribuciones
contribuciones = pca$var$contrib
contribuciones
fviz_contrib(pca, choice = "var", axes = 1)
```

4) Inteprete la contribución del primer plano factorial.

- Las caracteristicas que mas influyen en el CP1 son la metrica 5(indicador latencia), response time, query latency, batch jobs y job time. Esto significa que son las que mas contribuyen a la construccion del CP por ende, son las que mas influyeron en la direccion del componente principal 1.

Para el CP2 fueron: metric3, ddisk read, data size, ingestion rate y throughput. Misma interpretacion que antes.

```r
#contribuciones
contribuciones = pca$var$contrib
contribuciones
fviz_contrib(pca, choice = "var", axes = 1)
fviz_contrib(pca, choice = "var", axes = 2)
```

```
> contribuciones
                  Dim.1       Dim.2
cpu_usage      0.05680289  0.01685015
cpu_peak       0.05952871  0.01324858
cpu_idle       0.06683249  0.02126330
threads        0.04726073  0.03262966
processes      0.06503139  0.01012448
ram_usage      0.06408567  0.04439368
ram_peak       0.05457488  0.04661367
swap_usage     0.05827432  0.06577200
cache_usage    0.04946042  0.06380045
buffer_usage   0.05389901  0.05339017
disk_read      0.13743927 11.07742832
disk_write     0.16233889 10.78220333
io_wait        0.15549581 10.90580281
disk_queue     0.17208457  9.96229507
disk_latency   0.12199493 10.42011757
```

5) Aplique el criterio de valor propio como lo vimos en clase y compare el número de componentes sugerido con el scree plot.

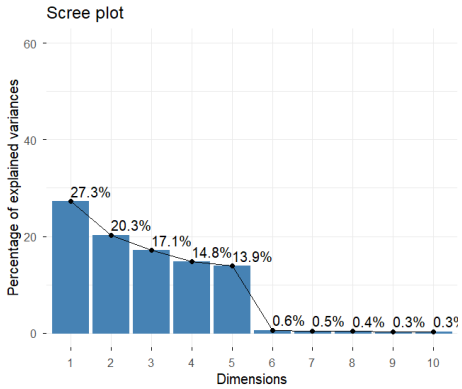

-Aplicando la regla del “codo” se puede ver que a partir de la componente #5 la varianza explicada por la CP cae, por ende el numero optimo de CP a seleccionar es #5 ademas de que con 5 CP obtenemos mas del 93% de varianza explicada superando el 70% mínimo sugerido en algunos libros (que se obtendría con 4 CP).